

Proyecciones Locales vs. VARs

El rol de las especificaciones de tendencia

Federico Ariel Lopez

December 5, 2025

Pregunta

Pregunta: ¿Son las estimaciones LP de funciones impulso-respuesta menos sensibles a la mala especificación de tendencia que los VARs?

- Las series económicas usualmente tienen tendencia (determinísticas, estocásticas, ...)
- Debemos elegir un método de eliminación de tendencia *antes* de estimar IRFs
- Supuesto de tendencia incorrecto \Rightarrow mala especificación. ¿Problema?

Literatura: El famoso resultado de Plagborg Moller et al se testeó mayormente con mala especificación en el número de rezagos.

Motivación

Los métodos LP estiman cada horizonte h directamente:

$$y_{t+h} = \alpha^h + \theta^h \varepsilon_t + \text{controles} + u_{t+h}$$

Los métodos VAR iteran hacia adelante desde:

$$Y_t = A_1 Y_{t-1} + \cdots + A_p Y_{t-p} + u_t$$

La estimación horizonte por horizonte de LP puede ser más robusta a la mala especificación que las restricciones entre ecuaciones del VAR.

Sabemos que LP tiene menor sesgo, mayor varianza (Li, Plagborg-Møller & Wolf, 2024).

Por verse: ¿Esto se mantiene para mala especificación de tendencia? (prior: sí)

Procesos Generadores de Datos

Modelo estructural de ejemplo: VAR(1), 2 variables, con componente de tendencia

$$Y_t = \mu_t + X_t, \quad X_t = AX_{t-1} + B\varepsilon_t, \quad \varepsilon_t \sim N(0, I_2)$$

Tres especificaciones de tendencia para μ_t :

DGP	Tendencia	Especificación
Estacionario	Ninguna	$\mu_t = 0$
Determinística	Lineal	$\mu_t = \delta \cdot t$
Estocástica	Raíz unitaria	$\mu_t = \mu_{t-1} + \eta_t$

IRF verdadera: $\theta_h = CA^hB$ donde C selecciona la variable de respuesta.

Para cada DGP: simular $S = 1000$ muestras de longitud $T \in \{100, 250, 500\}$.

Estimación

Paso 1: Eliminación de tendencia. Transformar Y_t observado usando:

Método	Transformación
Niveles	$\tilde{Y}_t = Y_t$
Tendencia lineal	$\tilde{Y}_t = Y_t - \hat{\alpha} - \hat{\beta}t$
Primera diferencia	$\tilde{Y}_t = \Delta Y_t$

Paso 2: Estimación de IRF. Sobre datos sin tendencia \tilde{Y}_t , estimar:

- **SVAR:** $\tilde{Y}_t = \hat{A}_1 \tilde{Y}_{t-1} + \cdots + \hat{A}_p \tilde{Y}_{t-p} + \hat{u}_t$, luego $\hat{\theta}_h^{VAR} = \hat{C} \hat{A}^h \hat{B}$
- **LP:** $\tilde{Y}_{t+h} = \hat{\alpha}_h + \hat{\theta}_h^{LP} \hat{\varepsilon}_{1t} + \hat{\gamma}'_h W_t + \hat{u}_{t+h}$

Comparación

Para cada simulación $s = 1, \dots, S$:

- ① Extraer datos del DGP $d \in \{\text{estacionario, lineal, raíz unitaria}\}$
- ② Aplicar eliminación de tendencia $m \in \{\text{niveles, lineal, diferencia}\}$
- ③ Estimar IRF mediante método $j \in \{\text{SVAR, LP}\}$
- ④ Registrar $\hat{\theta}_{h,s}^{(d,m,j)}$ e intervalo de confianza

Métricas de desempeño (Igual que el paper, promediadas sobre S replicaciones):

$$\text{Sesgo}_h = \frac{1}{S} \sum_s \left(\hat{\theta}_{h,s} - \theta_h^{\text{true}} \right), \quad \text{RMSE}_h = \sqrt{\frac{1}{S} \sum_s \left(\hat{\theta}_{h,s} - \theta_h^{\text{true}} \right)^2}$$

$$\text{Cobertura}_h = \frac{1}{S} \sum_s \mathbf{1} [\theta_h^{\text{true}} \in \text{CI}_{h,s}]$$

¿Cómo difieren las métricas entre $(DGP \times \text{eliminación de tendencia})$ cuando $DGP \neq \text{supuesto de tendencia}$?

Posibles extensiones que estan en los papers

- Simulaciones calibradas a datos reales
- Más métodos de estimación: BVAR con shrinkage, LP con penalización, model averaging
- Otros esquemas de identificación: instrumentos externos/proxy SVAR, restricciones de signo, identificación narrativa (Ramey, 2016)
- Comparar tendencias más complejas: quiebres estructurales, tendencias cuadráticas, raíces unitarias estacionales

Referencias

- Jordà, Ò. (2005). Estimation and inference of impulse responses by local projections. *American Economic Review*, 95(1), 161–182.
- Plagborg-Møller, M., & Wolf, C.K. (2021). Local projections and VARs estimate the same impulse responses. *Econometrica*, 89(2), 955–980.
- Kilian, L., & Lütkepohl, H. (2017). *Structural Vector Autoregressive Analysis*. Cambridge University Press.
- Montiel Olea, J.L., & Plagborg-Møller, M. (2021). Local projection inference is simpler and more robust than you think. *Econometrica*, 89(4), 1789–1823.